MACHINE LEARNING CANVAS

Designed for: Proyecto MiBici - MLOps, Semana 5 | Designed by: Equipo 15 - TC5061.10 | Date: 18/Oct/2026 | Iteration: 1

PREDICTION TASK

Proyecto con 3 preguntas analíticas:

- **P1 — Demanda:** Predecir salidas de viajes por estación-hora ***Granularidad:*** estación–hora. ***Horizonte propuesto:*** siguiente hora. ***Variable objetivo:*** número de salidas por estación y hora. ***Resultado:*** demanda estimada de bicicletas.
- **P2 — Riesgo proxy:** Clasificar si una estación presenta riesgo aproximado de desequilibrio entre llegadas y salidas. ***Granularidad:*** estación–hora. ***Horizonte propuesto:*** siguiente hora. ***Variable objetivo:*** riesgo proxy binario. ***Criterio:*** |llegadas – salidas| / capacidad ≥ 0.25.
- **P3 — Perfiles de uso:** Agrupar estaciones con patrones horarios similares de utilización.***Granularidad:*** estación. ***Horizonte:*** perfil histórico anual de 2024. ***Resultado:*** grupo de comportamiento asignado mediante K-Means.

DECISIONS

- Los operadores utilizan la demanda estimada por estación y hora para planear la cantidad y distribución de bicicletas, anticipando horarios de mayor utilización.
- El equipo de rebalanceo utiliza la clasificación del riesgo proxy para priorizar estaciones que podrían requerir revisión y redistribución de bicicletas.
- El equipo de planeación utiliza los grupos de estaciones para comparar patrones de utilización y apoyar decisiones sobre capacidad, ubicación y posibles ampliaciones del sistema.
- Los resultados sirven como apoyo a las decisiones humanas; no se automatizan movimientos de bicicletas ni cambios operativos.

VALUE PROPOSITION

- **Problema:** la utilización de bicicletas cambia según la estación, el horario y el tipo de día. Estas variaciones dificultan anticipar la demanda y organizar el rebalanceo.
- **P1:** permite anticipar periodos de alta demanda y planear mejor la distribución de bicicletas.
- **P2:** ayuda a identificar estaciones con posibles desequilibrios entre llegadas y salidas, priorizando su análisis operativo.
- **P3:** permite reconocer estaciones con comportamientos similares para orientar decisiones de planeación y capacidad.
- **Beneficio esperado:** utilizar información histórica para mejorar la planificación operativa, el aprovechamiento de recursos y, potencialmente, la disponibilidad del servicio.

DATA COLLECTION

- **Fuente:** datos abiertos de MiBici, sistema de bicicleta pública del Área Metropolitana de Guadalajara.
- **Periodo analizado:** enero–diciembre de 2024.
- **Volumen:** 4,645,921 viajes distribuidos en 12 archivos CSV mensuales.
- **Datos de viajes:** identificador, fecha y hora de inicio y fin, estación de origen y destino.
- **Datos de estaciones:** nomenclatura de septiembre de 2026, con 484 estaciones, ubicación y capacidad.
- **Justificación técnica:** Se seleccionó 2024 por contar con 12 meses completos en el portal de MiBici, garantizando reproducibilidad, trazabilidad y evaluación. Revisando 2023, encontramos que abril y mayo no presentan enlaces visibles de descarga, mientras que 2025 también dispone de 12 meses y representa una alternativa viable si es necesario su utilización.

DATA SOURCES

Ingesta automatizada: `mibici/dataset.py` descarga los archivos de viajes y estaciones.
Procesamiento: normalización de encabezados, codificaciones, fechas y tipos de datos; validación de registros inválidos y duplicados.
Almacenamiento: CSV originales en `data/raw/` y datos procesados en formato Parquet.
Versionado: manifiesto con registros y hashes SHA-256.
Resultado validado: 4,645,921 viajes procesados y versión de datos `7e1470ac0632`.
Actualización propuesta: incorporar nuevos períodos y repetir las validaciones mediante el pipeline.

IMPACT SIMULATION

- **Costos y beneficios:** P1 busca reducir la falta o el exceso de bicicletas; P2, evitar rebalanceos innecesarios (falsas alarmas) y riesgos no detectados; P3, mejorar las decisiones de capacidad y ubicación. Los costos monetarios aún no están cuantificados.
- **Datos para simulación:** Viajes históricos de MiBici 2024 (4,645,921 registros), estaciones, capacidades y patrones horarios. Se utilizarán particiones cronológicas para simular decisiones sobre datos no utilizados en el entrenamiento.
- **Criterios de despliegue:** Mejorar las métricas de los baselines (MAE/RMSE, precision/recall/F1 y Silhouette/Davies–Bouldin), validar la utilidad operativa y asegurar reproducibilidad. P2 requerirá validar su indicador proxy con información real de disponibilidad antes de utilizarlo para decisiones operativas.
- **Equidad:** Evaluar el desempeño por zonas, estaciones y horarios para evitar favorecer sistemáticamente áreas de

MAKING PREDICTIONS

- **Tipo de ejecución:** Procesamiento por lotes (batch) mediante scripts Python, sin requerir predicciones en tiempo real.
- **Frecuencia:** Para P1 y P2 se propone ejecución cada hora para estimar la demanda y el riesgo proxy de la siguiente hora. Para P3 se propone ejecución trimestral para actualizar la agrupación de estaciones.
- **Tiempo disponible:** Para P1 y P2 se propone completar el procesamiento de variables, la predicción y la entrega de resultados antes del siguiente ciclo horario (máximo 60 minutos). P3 se ejecutaría fuera del horario operativo, sin restricciones de respuesta inmediata.
- **Recursos:** Procesamiento mediante CPU, utilizando Python, pandas, NumPy y scikit-learn, con datos almacenados en formato Parquet.
- **Decisiones:** Los operadores utilizarían P1 para planear la demanda, P2 para priorizar el rebalanceo y P3 para apoyar

BUILDING MODELS

- **P1 —** Regresión evaluada con MAE y RMSE.
- **P2 —** Clasificación binaria evaluada con precisión, recall y F1-score.
- **P3 —** Clustering mediante K-Means, evaluado con Silhouette Score y Davies–Bouldin Index.
- **Actualización:** Se propone reentrenar P1 y P2 mensualmente con nuevos viajes; P3, trimestralmente para identificar cambios en los perfiles de estaciones.
- **Tiempo:** Entrenamiento batch, incluyendo ingesta, preparación, feature engineering y evaluación.
- **Recursos:** Python 3.12, pandas, scikit-learn y MLflow; procesamiento local mediante CPU y almacenamiento CSV/Parquet. No se requieren GPU para los baselines actuales.
- **Seguimiento:** experimentos registrados en MLflow bajo `mibici-equipo15`

FEATURES

- **P1:** salidas por estación y hora, día de semana, hora del día y comportamiento histórico.
- **P2:** llegadas, salidas, balance horario, capacidad y presión relativa para construir la etiqueta proxy. Las variables predictoras deben provenir del calendario o de periodos anteriores.
- **P3:** 48 proporciones horarias de utilización (24 para días laborales y 24 para fines de semana), más el logaritmo de la media diaria de salidas.
- **Implementación:** funciones reutilizables en `mibici/features.py`.
- **Prevención de fuga temporal:** separación cronológica y uso de información histórica para construir las predicciones.

alta demanda y perjudicar estaciones periféricas o de menor utilización.

la planeación de estaciones.

MONITORING

Métricas de ML:

- **P1:** MAE y RMSE para evaluar la precisión de la demanda estimada.
- **P2:** precision, recall y F1 para evaluar la identificación de riesgos.
- **P3:** Silhouette y Davies–Bouldin para evaluar la calidad de los agrupamientos.

KPIs de usuarios: disponibilidad de bicicletas y anclajes, tiempo de espera y porcentaje de solicitudes no atendidas.

KPIs del negocio: eficiencia del rebalanceo, costo operativo por traslado, utilización de estaciones y cumplimiento de niveles de servicio.

Frecuencia de revisión: KPIs operativos diariamente; métricas de P1 y P2 semanalmente; agrupamientos de P3 trimestralmente.

Seguimiento: MLflow para registrar experimentos y desempeño; controles de calidad y versionado de datos para asegurar trazabilidad.

Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing.